Projeto: Análise do AQI em São Paulo e Puebla

1. Introdução

O AQI (Air Quality Index) é um indicador amplamente utilizado para avaliar a qualidade do ar, baseado na concentração de poluentes atmosféricos que impactam diretamente a saúde humana.

Entre esses poluentes, destacam-se as partículas inaláveis PM2.5 e PM10, que são componentes críticos no cálculo do índice:

- PM2.5 → partículas muito finas (≤ 2,5 µm), capazes de penetrar profundamente nos pulmões e atingir a corrente sanguínea
- PM10 → partículas maiores (≤ 10 µm), que afetam principalmente as vias respiratórias superiores

A exposição a esses poluentes está associada a diversos problemas de saúde, como doenças respiratórias e cardiovasculares, tornando sua análise essencial em ambientes urbanos.

Nesse contexto, este projeto propõe a análise da relação entre essas variáveis por meio de diferentes abordagens de modelagem, buscando compreender tanto os efeitos diretos quanto indiretos na qualidade do ar.

2. Objetivo

O objetivo deste projeto é analisar o impacto das partículas inaláveis PM2.5 e PM10 sobre o índice de qualidade do ar (AQI), por meio da construção e comparação de diferentes modelos de regressão.

Para isso, foram desenvolvidas três abordagens:

- Um modelo baseado em poluentes diretos (PM2.5 e PM10)
- Um modelo baseado em variáveis urbanas e ambientais (CO_2, veículos, indústria, densidade populacional, entre outros)
- Um modelo completo, combinando todas as variáveis

Além disso, o estudo compara o comportamento desses modelos em duas cidades com contextos distintos:

- São Paulo (Brasil)

- Puebla (México)

Com essa abordagem, busca-se não apenas quantificar o impacto das variáveis, mas também compreender a estrutura do fenômeno, diferenciando fatores diretos e indiretos na determinação da qualidade do ar, bem como avaliar qual modelo apresenta maior capacidade explicativa.

3. Dados

O conjunto de dados utilizado contém informações relacionadas à qualidade do ar e a fatores ambientais e urbanos, permitindo uma análise mais abrangente do fenômeno da poluição atmosférica.

As principais variáveis consideradas foram:

- **AQI (Air Quality Index)**
- **PM2.5**
- **PM10**

Além dessas, o dataset inclui variáveis urbanas e ambientais, como:

- **Emissões de CO_2**
- **Crescimento da frota de veículos**
- **Atividade industrial**
- **Densidade populacional**
- **Proporção de áreas verdes**

Esse conjunto de dados possibilita não apenas a análise da relação direta entre partículas e qualidade do ar, mas também a investigação de influências indiretas provenientes do contexto urbano, permitindo estruturar o problema em diferentes níveis de análise.

Dessa forma, os dados suportam a construção de modelos distintos, voltados à avaliação de fatores diretos, indiretos e combinados na determinação do AQI.

4. Tratamento dos dados

Para garantir a qualidade das análises e a confiabilidade dos modelos, foi realizado um processo de tratamento e preparação dos dados, com o objetivo de reduzir ruídos, inconsistências e possíveis distorções estatísticas.

Foram aplicadas as seguintes etapas:

- **Remoção de valores nulos (dropna):**
  Exclusão de registros incompletos nas variáveis utilizadas, assegurando consistência na modelagem.
- **Filtragem de valores fora do intervalo esperado:**
  Remoção de observações consideradas atípicas ou inválidas, como:
  - **AQI > 500**
  - **PM2.5 > 500**
  - **PM10 > 500**
  - **Valores negativos**

Essa etapa visa eliminar possíveis outliers ou inconsistências que poderiam comprometer o desempenho dos modelos.

- **Padronização da leitura do arquivo:**
  Ajuste do separador e do formato decimal do CSV, garantindo correta interpretação dos dados pelo ambiente de análise.

5. Metodologia

Para analisar a relação entre poluentes, fatores urbanos e a qualidade do ar, foi aplicada a técnica de **Regressão Linear Múltipla**, com o objetivo de quantificar o impacto das variáveis sobre o **AQI (Air Quality Index)**.

A abordagem foi estruturada em **três modelos distintos**, visando comparar diferentes níveis de explicação do fenômeno:

Modelo 1 – Direto (Poluentes)

- **Variáveis independentes:**
  - **PM2.5**
  - **PM10**

- **Variável dependente:**
    - **AQI**

Objetivo: avaliar o impacto **direto** das partículas na qualidade do ar.

Modelo 2 – Indireto (Urbano)

- **Variáveis independentes:**
    - **Vehicles_Increase_%**
    - **Industries_Increase_%**
    - **CO2_Emissions_MT**
    - **Green_Space_Ratio_%**
    - **Population_Density_Per_SqKm**
- **Variável dependente:**
    - **AQI**

Objetivo: analisar o efeito de fatores urbanos e ambientais, que atuam de forma indireta na poluição.

Modelo 3 – Completo (Híbrido)

- Combinação de todas as variáveis dos modelos anteriores

Objetivo: verificar se a integração entre fatores diretos e indiretos melhora o desempenho preditivo do modelo.

Procedimento de modelagem

Para cada modelo, foi realizado o seguinte processo:

- Divisão do conjunto de dados em:
    - **80% para treinamento**, utilizado para ajuste dos parâmetros
    - **20% para teste**, utilizado para avaliar a capacidade de generalização
- Aplicação de **padronização (StandardScaler)** nos modelos com variáveis de diferentes escalas, garantindo comparabilidade entre coeficientes
- Avaliação dos modelos por meio das métricas:
    - **R^2 (coeficiente de determinação)** → mede o poder explicativo

6. Resultado

Modelo 1 – Direto (Poluentes)

São Paulo e Puebla (padrão geral)

Variáveis: PM2.5 e PM10

- **$R^2 \approx 0.86 – 0.87$**
- **Coeficientes aproximados:**
  - **PM2.5 ≈ 0.68**
  - **PM10 ≈ 0.54**

O modelo apresentou alto poder explicativo, indicando que cerca de 86% a 87% da variação do AQI é explicada pelas partículas.

Interpretação:

- **PM2.5 é o fator mais relevante**
- **Relação forte e direta com o AQI**

Modelo 2 – Indireto (Urbano)

Variáveis:
CO2, veículos, indústria, densidade populacional, área verde

- **$R^2 \approx 0.40 – 0.50$**

Coeficientes (padronizados):

- **CO2 ≈ 0.20 – 0.30**
- **Vehicles ≈ 0.10 – 0.25**
- **Industries ≈ 0.10 – 0.30**
- **Population Density ≈ 0.20 – 0.35**
- **Green Space ≈ -0.05 a -0.15**

O modelo apresentou baixo poder explicativo, indicando que variáveis urbanas isoladas não conseguem explicar diretamente o AQI.

Interpretação:

- **Influência existe**
- **Mas é indireta e limitada**

Modelo 3 – Completo (Híbrido)

Variáveis: todas (poluentes + urbanas)

- **$R^2 \approx 0.87 – 0.88$**

Coeficientes (padronizados):

- **PM2.5 → maior peso relativo**
- **PM10 → segundo maior impacto**
- **Variáveis urbanas → impacto reduzido após controle das partículas**

O modelo completo apresentou um leve ganho de performance, porém sem melhoria significativa em relação ao modelo 1.

Intepretação:

- **Melhor para previsão**
- **Menos interpretável**

Comparação geral

Os resultados indicam que:

- O modelo 1 baseado em poluentes apresenta maior capacidade explicativa
- O modelo 2 focado urbano isolado não é suficiente para explicar o AQI
- O modelo 3 pegando várias variáveis melhora marginalmente o desempenho, mas não altera de forma significativa a explicação do fenômeno

7. Interpretação dos coeficientes na prática

A análise dos coeficientes do modelo baseado em poluentes indica que o PM2.5 apresenta maior impacto sobre o AQI em comparação ao PM10, evidenciando que partículas mais finas possuem maior influência na deterioração da qualidade do ar.

Em termos quantitativos:

- Para cada aumento de 1 unidade em PM2.5, o AQI aumenta aproximadamente 0.68 pontos
- Para cada aumento de 1 unidade em PM10, o AQI aumenta aproximadamente 0.54 pontos

Essa diferença indica que, para variações equivalentes, o PM2.5 exerce um efeito mais intenso sobre o índice.

Considerando variações maiores:

- Um aumento de 10 unidades em PM2.5 eleva o AQI em aproximadamente 6.8 pontos
- Um aumento de 10 unidades em PM10 eleva o AQI em aproximadamente 5.4 pontos

Esses resultados demonstram que pequenas variações na concentração de partículas já são suficientes para produzir impactos mensuráveis na qualidade do ar.

Do ponto de vista ambiental e sanitário, esse comportamento é consistente com a natureza das partículas: o PM2.5, por possuir menor dimensão, apresenta maior capacidade de penetração no sistema respiratório, estando frequentemente associado a fontes como combustão, tráfego veicular e atividade industrial.

Dessa forma, os coeficientes estimados reforçam que o controle de emissões relacionadas ao PM2.5 tende a produzir efeitos mais relevantes na melhoria da qualidade do ar em ambientes urbanos.

8. Insights principais

1. A resposta do AQI às variações de PM2.5 e PM10 apresentou comportamento semelhante em São Paulo e Puebla, indicando que o impacto dessas partículas segue um padrão consistente em diferentes contextos urbanos.

2. Os elevados valores de R^2 observados nos modelos baseados em poluentes indicam que a qualidade do ar é majoritariamente explicada pela concentração de partículas, evidenciando o papel central de PM2.5 e PM10 na determinação do AQI.

3. O PM2.5 apresentou coeficientes superiores ao PM10 em ambas as cidades, indicando maior sensibilidade do AQI a variações de partículas finas, o que está alinhado com sua maior capacidade de dispersão e penetração no ambiente e no organismo humano.

4. A forte relação linear observada entre as variáveis sugere um comportamento proporcional, no qual variações nas concentrações de partículas resultam em mudanças previsíveis no AQI, favorecendo a modelagem e interpretação do fenômeno.

5. A consistência dos coeficientes entre as cidades indica robustez na relação entre partículas e qualidade do ar, mesmo diante de diferenças ambientais e urbanas, reforçando a estabilidade dos resultados obtidos.

6. A comparação entre modelos indica que variáveis urbanas apresentam contribuição limitada quando analisadas isoladamente, atuando principalmente como fatores indiretos na formação de partículas.

7. Do ponto de vista prático, os resultados sugerem que estratégias de melhoria da qualidade do ar devem priorizar a redução de partículas finas (PM2.5), dado seu maior impacto relativo sobre o AQI.

9. Limitações

Apesar dos bons resultados obtidos, o modelo apresenta algumas limitações importantes:

- O uso de um modelo de regressão linear assume uma relação estritamente linear entre as variáveis, o que pode não capturar comportamentos mais complexos ou não lineares presentes na dinâmica da poluição atmosférica.
- A análise foi restrita a variáveis diretamente relacionadas ao AQI (PM2.5 e PM10), não incorporando outros fatores relevantes, como condições climáticas, atividades industriais específicas ou variações sazonais.
- O conjunto de dados utilizado é sintético, ainda que baseado em estatísticas realistas, o que limita a aplicação dos resultados para inferências no mundo real ou tomada de decisão.

- Possíveis relações entre variáveis (como correlação entre poluentes e fatores urbanos) não foram exploradas em profundidade, podendo haver efeitos indiretos não capturados pelo modelo.

10. Possíveis melhorias

Com base nas limitações identificadas, algumas melhorias podem ser consideradas para aprofundar a análise e aumentar a robustez dos resultados:

- Ampliar o conjunto de variáveis explicativas:
  Incluir e explorar de forma mais estruturada variáveis como emissões de CO_2, crescimento da frota de veículos, atividade industrial, densidade populacional e áreas verdes, com foco em compreender melhor os fatores indiretos que influenciam a formação de partículas.

- Explorar modelagem em múltiplas etapas:
  Desenvolver abordagens que representem a estrutura do fenômeno, como a modelagem da relação entre variáveis urbanas e partículas (PM2.5/PM10), seguida da relação entre partículas e AQI, permitindo uma interpretação mais próxima de um fluxo causal.

- Aplicar modelos mais avançados:
  Testar algoritmos capazes de capturar relações não lineares e interações entre variáveis, como árvores de decisão, Random Forest e métodos ensemble, visando avaliar possíveis ganhos de desempenho em relação à regressão linear.

- Aprimorar o tratamento e padronização dos dados:
  Avaliar o impacto de diferentes técnicas de normalização e padronização, especialmente em modelos com múltiplas variáveis, para melhorar a estabilidade e a comparabilidade dos coeficientes.

- Realizar análise temporal:
  Considerar a evolução dos dados ao longo do tempo (anos ou meses), permitindo identificar tendências, sazonalidade e possíveis mudanças estruturais no comportamento da poluição.

- Expandir a análise geográfica:
  Incluir outras cidades ou regiões, possibilitando validar a consistência dos padrões observados e ampliar a generalização dos resultados.

11. Conclusão (versão aprimorada)

A análise realizada evidencia que as partículas inaláveis PM2.5 e PM10 constituem os principais determinantes do AQI nas cidades estudadas, apresentando forte relação linear com a qualidade do ar.

Os resultados demonstram que o modelo baseado em poluentes diretos foi capaz de explicar a maior parte da variação do índice, confirmando que a concentração de partículas é o fator predominante na degradação da qualidade do ar. Em contraste, modelos baseados exclusivamente em variáveis urbanas apresentaram menor capacidade explicativa, indicando que esses fatores atuam de forma indireta, influenciando a formação dos poluentes, mas não o índice de forma imediata.

A consistência dos coeficientes e do desempenho dos modelos entre São Paulo e Puebla sugere que a dinâmica da poluição atmosférica segue um padrão estrutural relativamente estável entre diferentes contextos urbanos, reforçando a robustez dos resultados obtidos.

Adicionalmente, o PM2.5 apresentou impacto superior ao PM10 em ambas as cidades, evidenciando maior sensibilidade do AQI a variações de partículas finas. Esse resultado é coerente com a natureza dessas partículas, que possuem maior capacidade de dispersão e penetração, estando frequentemente associadas a fontes críticas como combustão e atividade veicular.

De forma geral, os resultados indicam que a qualidade do ar pode ser compreendida a partir de uma estrutura em dois níveis: fatores urbanos atuam como mecanismos indiretos, enquanto as partículas representam o elo direto na determinação do AQI.

Assim, do ponto de vista aplicado, estratégias voltadas à melhoria da qualidade do ar tendem a ser mais eficazes quando direcionadas à redução de partículas finas, especialmente o PM2.5, dado seu impacto mais significativo sobre o índice e suas implicações para a saúde pública.

12. Referências

Os dados utilizados neste projeto foram obtidos na plataforma **Kaggle**:

ASHYOU09. *Global Air Quality and Deforestation Dataset*.
Disponível em: https://www.kaggle.com/datasets/ashyou09/global-air-quality-and-deforestation-dataset
Acesso em: 19/04/2026

O conjunto de dados foi compilado com base em indicadores ambientais, urbanos e socioeconômicos inspirados em fontes globais, incluindo:

- Organização Mundial da Saúde (OMS / WHO) – Banco de Dados Global de qualidade do Ar
- Banco Mundial (World Bank) – Indicadores de Desenvolvimento Mundial
- Global Forest Watch (WRI) – Dados de desmatamento e mudanças florestais
- Programa das Nações Unidas para o Meio Ambiente (UNEP) – Relatórios ambientais
- Dados de Observação da Terra da NASA
- Agências nacionais de proteção ambiental e relatórios estatísticos urbanos
- Plataforma OpenAQ

A estrutura e os intervalos de dados seguem padrões típicos de monitoramento ambiental utilizados por essas organizações.

13. Repositório do Projeto

O código e os arquivos utilizados neste projeto estão disponíveis no GitHub:

https://github.com/jvreiscode/aqi-analysis-sao-paulo-puebla

O repositório contém:

- Código em Python utilizado na análise
- Base de dados utilizada
- Gráficos gerados
- Documentação do projeto (README)